Generalização cross-dataset em IDS

FINAL DA FASE 1 | geração 15/15 | Fase 2: 2/2 avaliações (inclui baseline)

Eu registrei na fronteira: 1 soluções, de 3 a 3 atributos entre 37 candidatos. F1-macro cross médio entre 0.0673 e 0.0673.

Eu utilizei uma árvore de decisão com profundidade 8 e pesos balanceados, dados completos das bases do experimento e transferência em todas as direções. A média das direções e a proporção de atributos são os objetivos do NSGA-II.

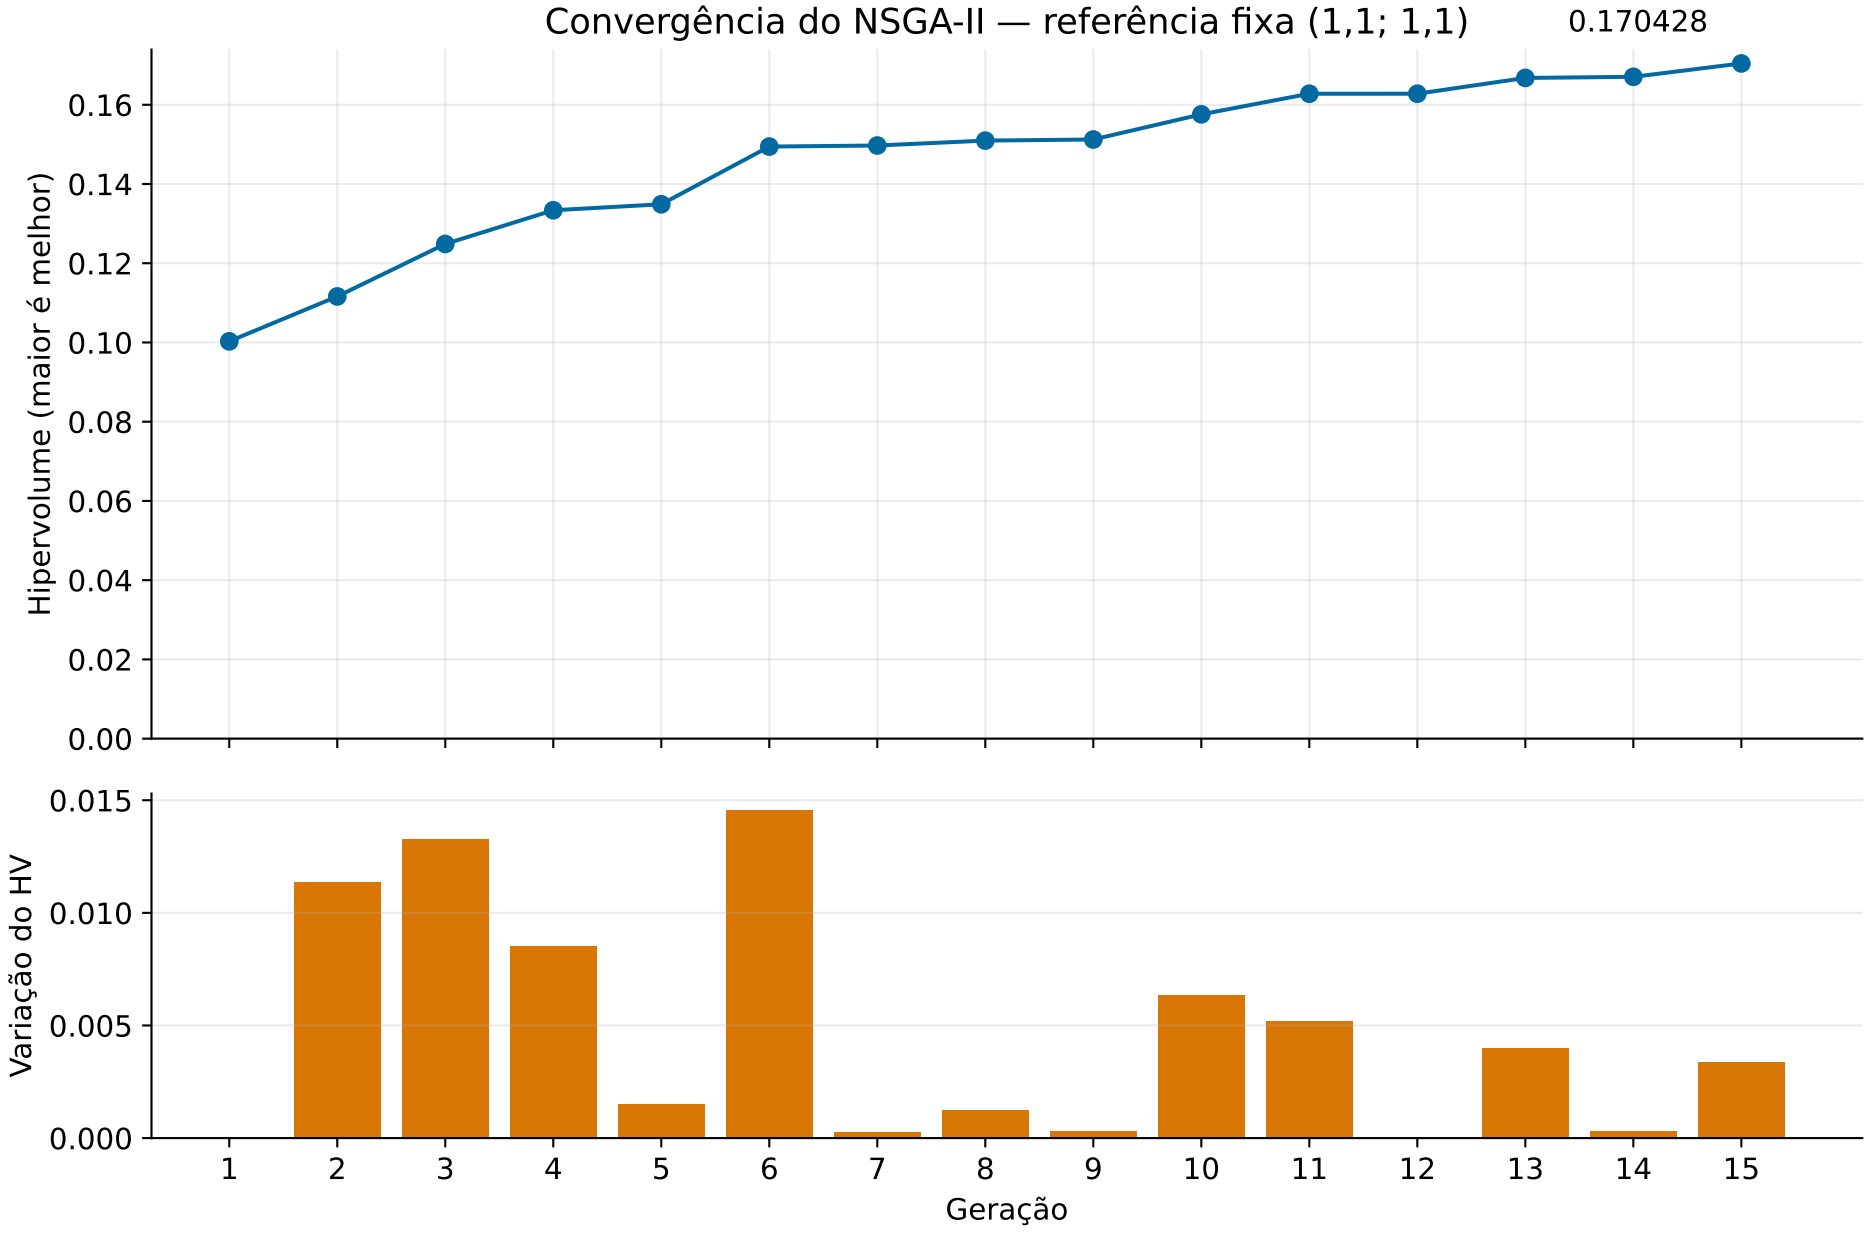
Leitura do F1: na implementação atual, classes do destino ausentes no treino são agrupadas no código -1. Não se calcula o F1 individual de cada categoria desconhecida original.

Eu particiono o erro por fração de amostras; não decomponho o F1 nem identifico causalmente domain shift. A coluna sem correspondência nas matrizes agrupa previsões fora do vocabulário do destino.

Eu utilizei as bases da transferência na seleção de atributos. Não realizei teste externo independente nesta rodada e utilizei uma única seed.

Os gráficos intra-dataset aparecem apenas quando houver avaliações detalhadas concluídas. O pacote parcial não contém essa etapa. Os resultados parciais podem mudar ao concluir a geração 15.

Rastreabilidade: veja dados_utilizados.json, resumo_solucoes.csv e LEIA-ME.md no mesmo pacote. Fonte: Resultados/pareto/pareto_20260907_000921_decision_tree.json



FINAL DA FASE 1 | geração 15/15 | Fase 2: 2/2 avaliações (inclui baseline)

Diagnóstico da busca multiobjetivo

Hipervolume: 0.100282 na geração 1 e 0.170428 na geração 15. Variação na última geração: +0.003375. Houve melhora na última geração; a curva não sustenta afirmar estabilização ao encerrar.

Objetivos minimizados: f1 = 1 − F1 cross médio; f2 = k/37. Ambos já estão em [0,1]. Referência fixa r = (1.1, 1.1), pior que todos os valores possíveis. Não há normalização diferente por geração.

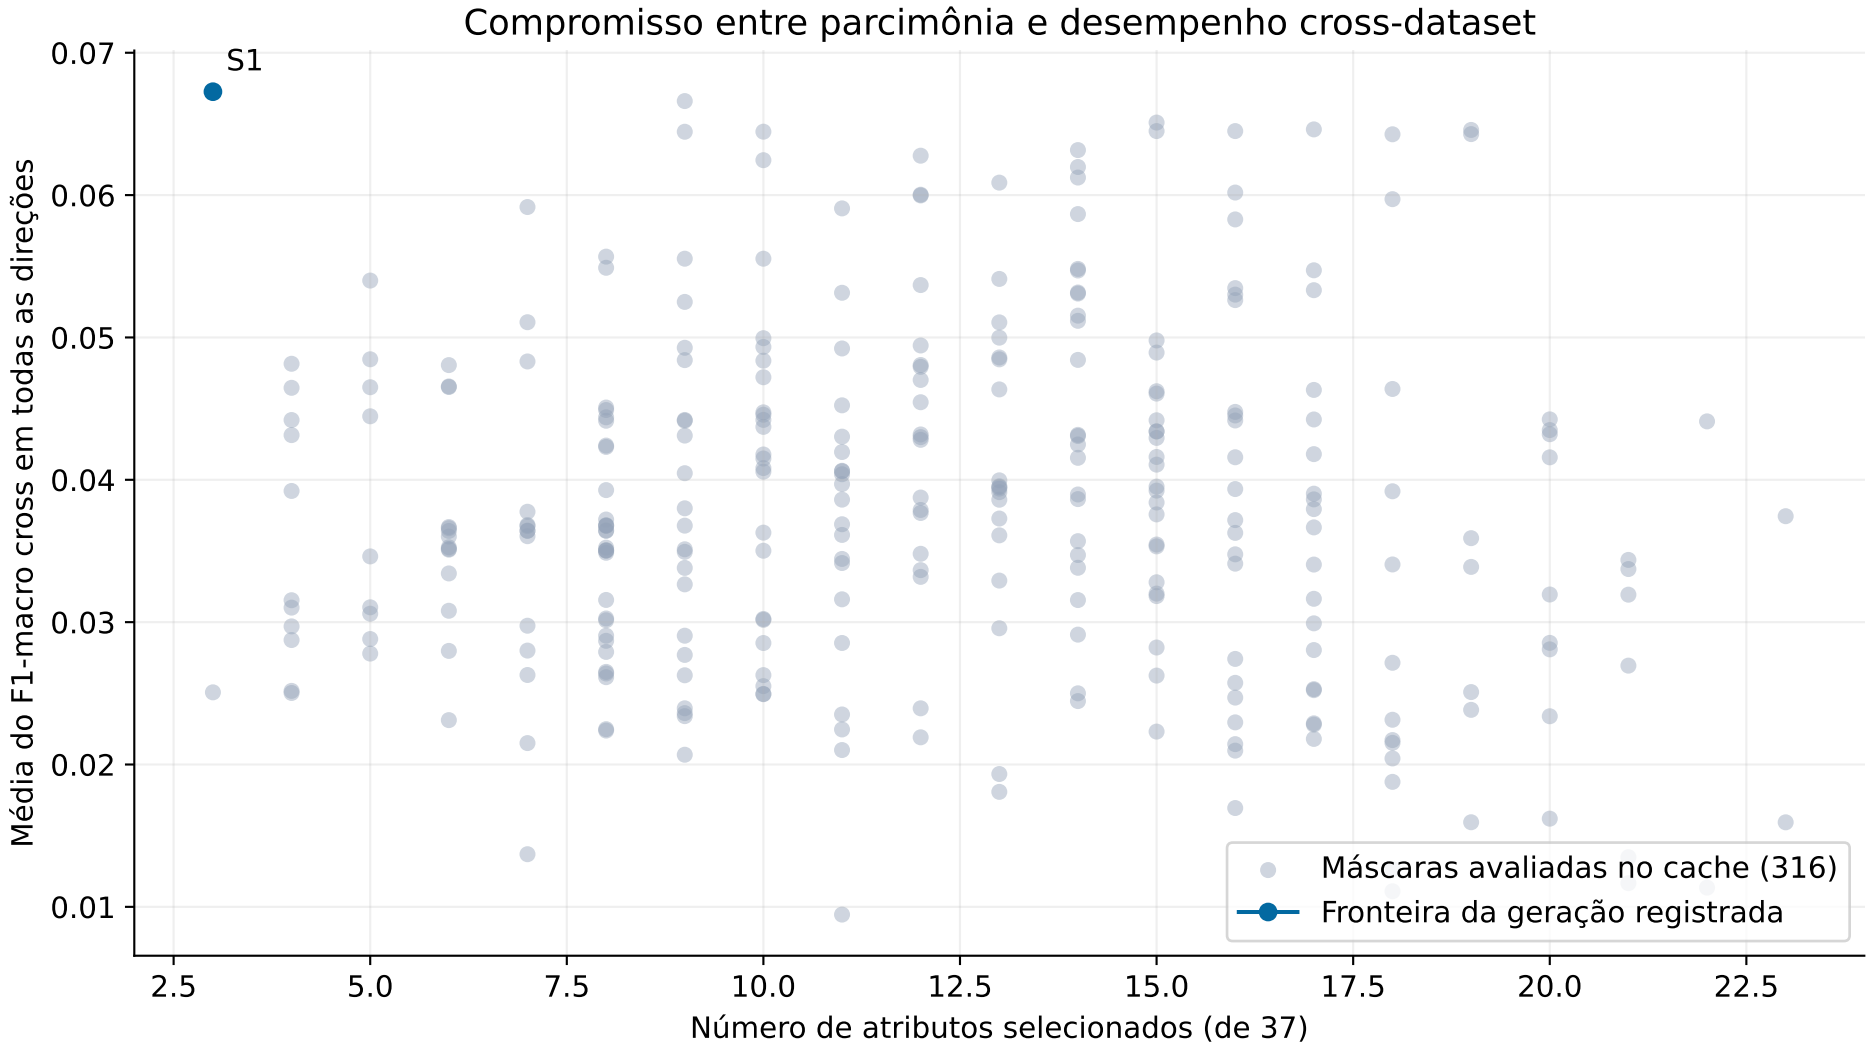
A curva mede o hipervolume da fronteira da população sobrevivente em cada geração, não de um arquivo acumulado de todas as soluções já visitadas. O NSGA-II não otimiza diretamente o hipervolume; ele pode oscilar.

Replay determinístico com cache somente leitura; fronteira final conferida por máscaras e objetivos. Nenhum modelo foi retreinado para recuperar esta curva. O cache não foi alterado.

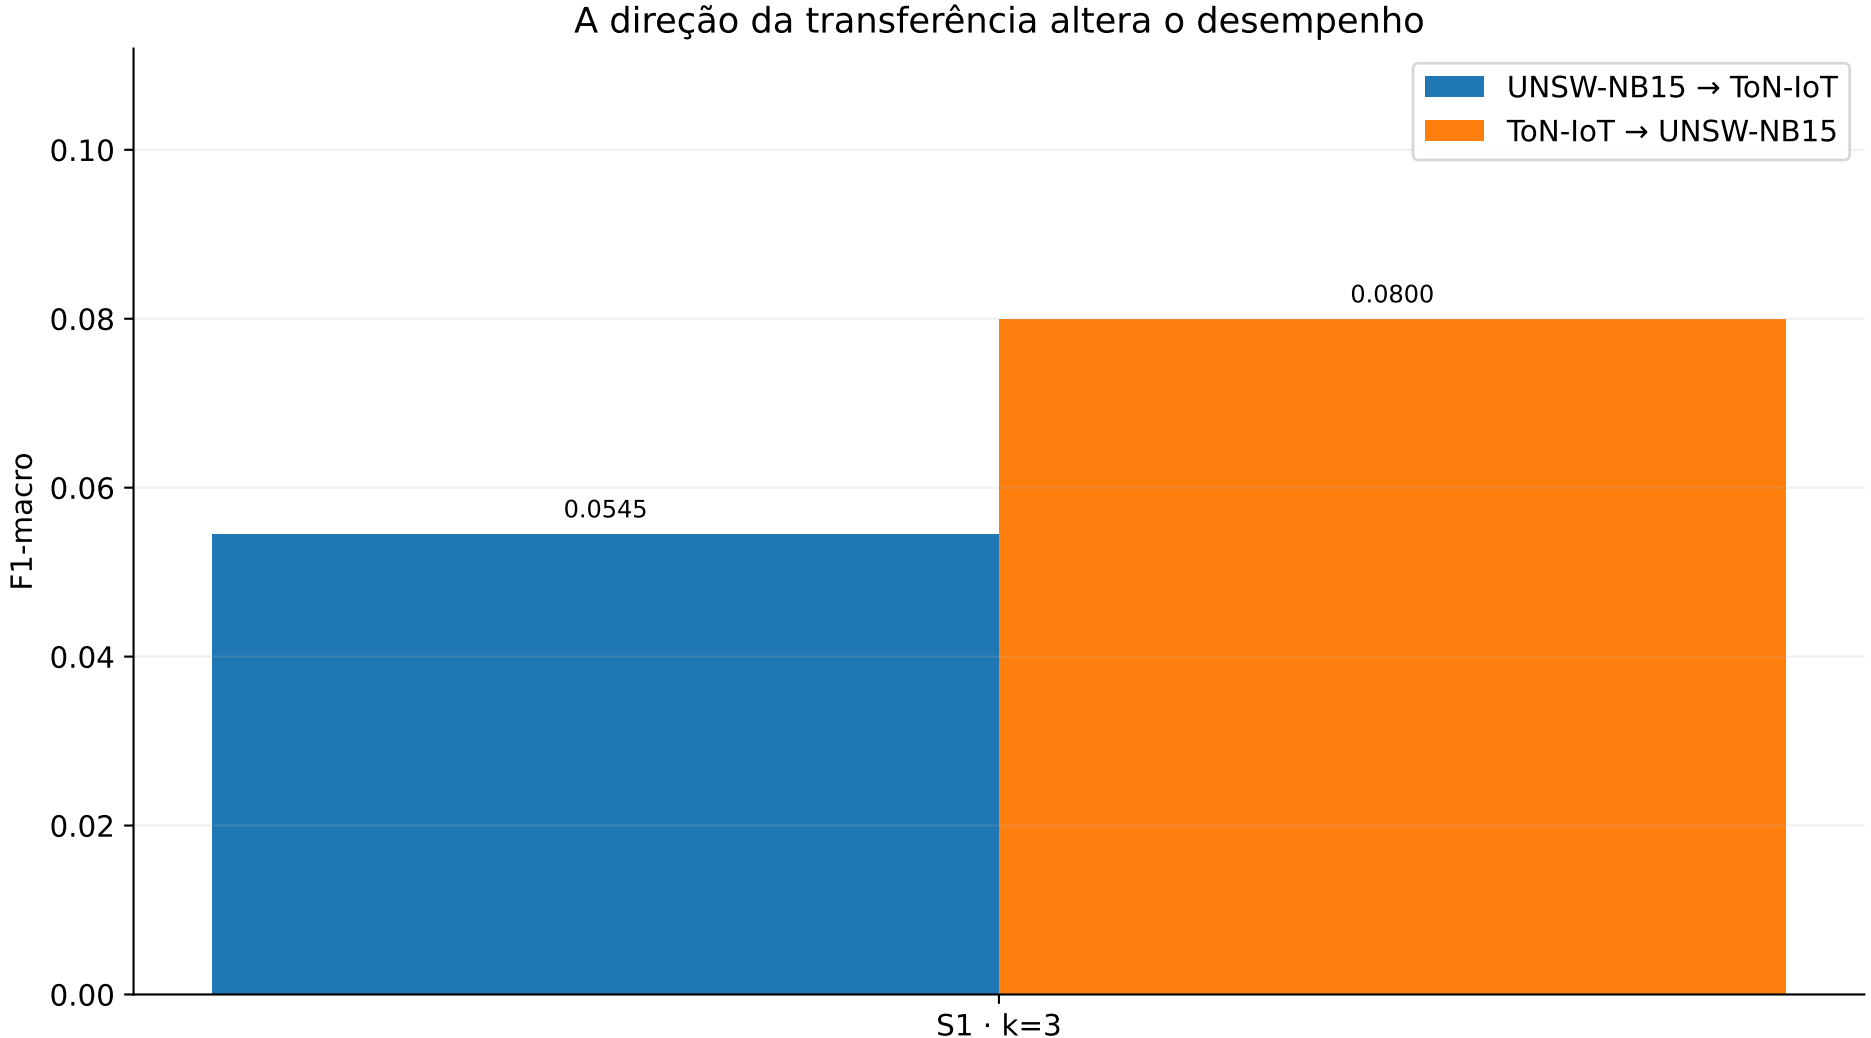
Melhora do hipervolume mostra progresso nos objetivos definidos. Não comprova ótimo global nem melhora de generalização em teste independente. Uma única seed e 15 gerações não estabelecem robustez.

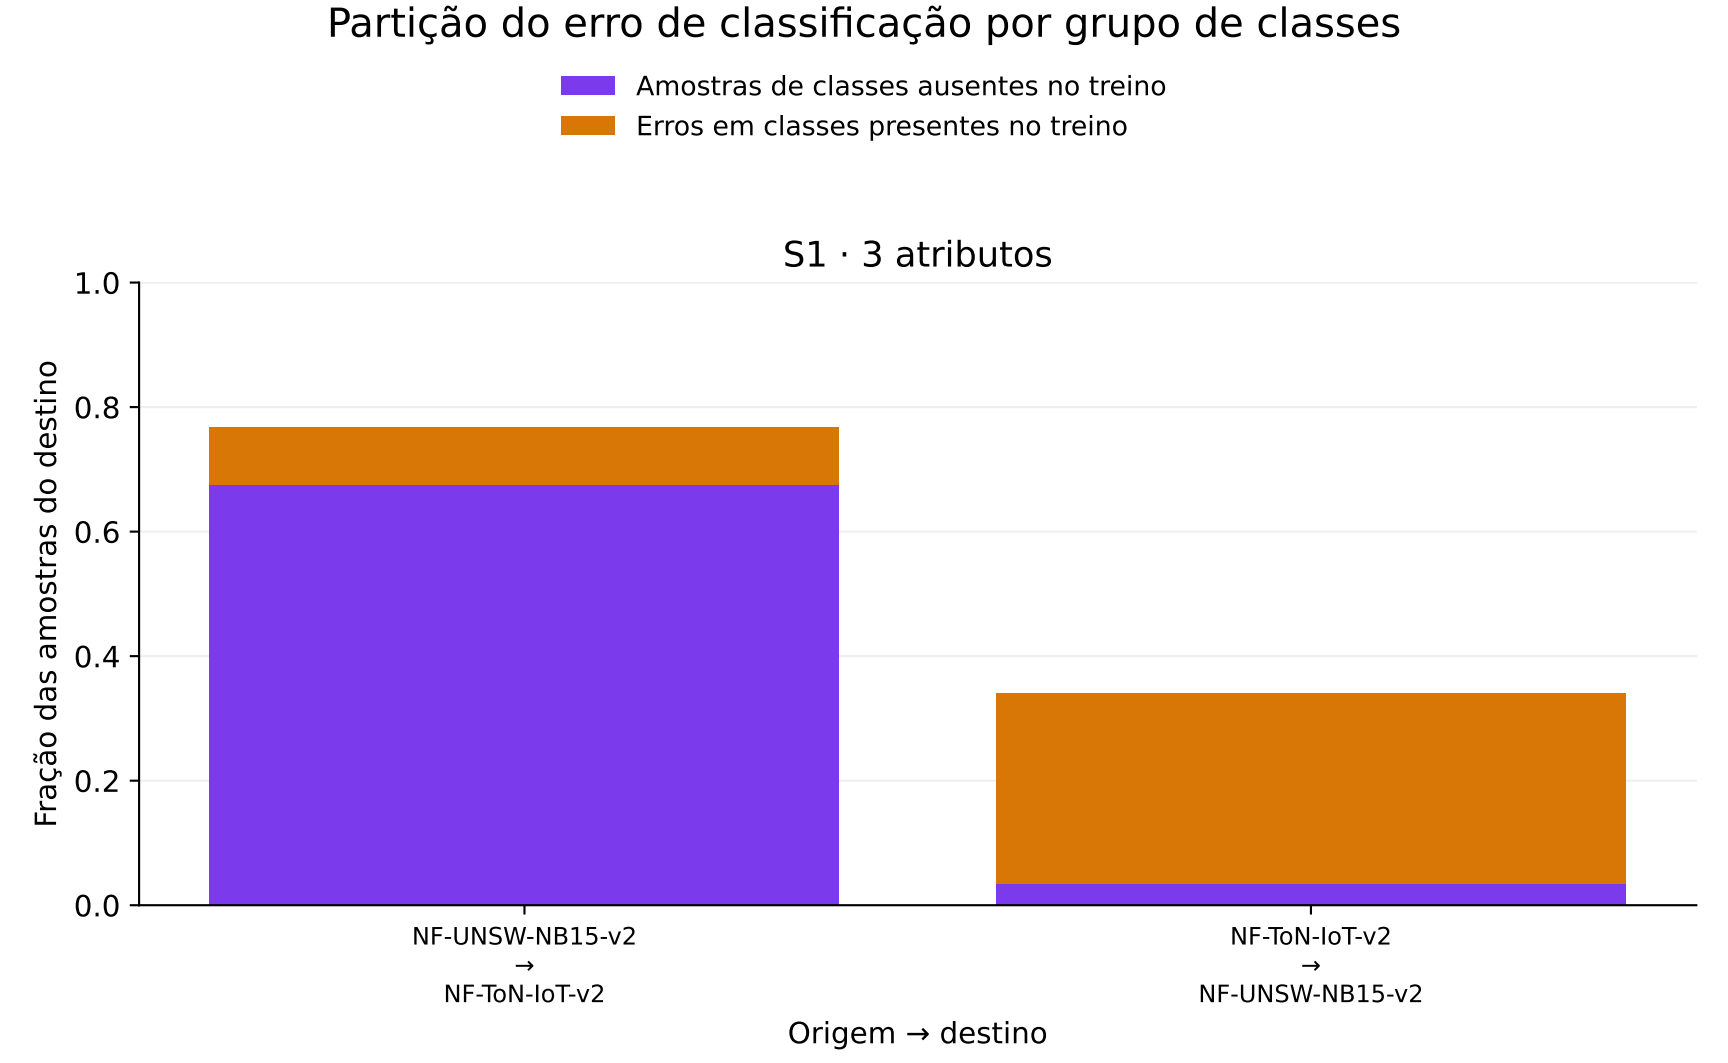
Fonte metodológica: pymoo — Analysis of Convergence: https://pymoo.org/getting_started/part_4.html

Os valores por geração e as fronteiras reconstruídas estão em convergencia_nsga2.csv e dados_utilizados.json.

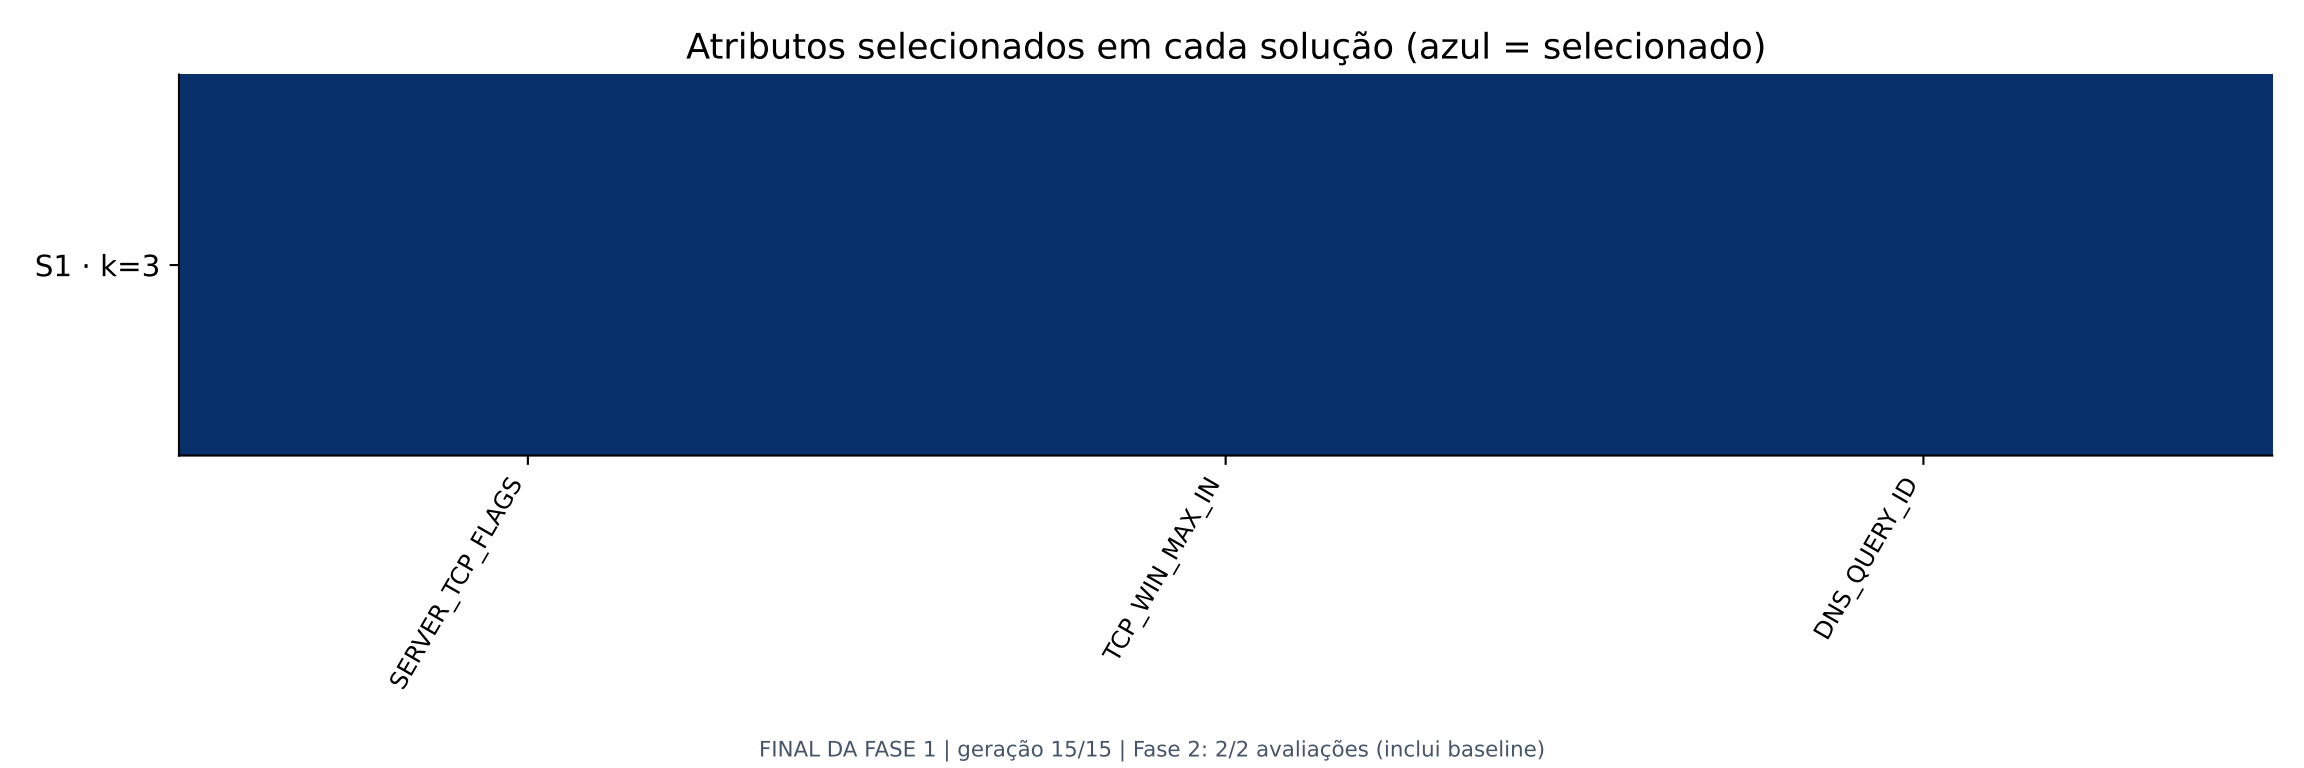


FINAL DA FASE 1 | geração 15/15 | Fase 2: 2/2 avaliações (inclui baseline)

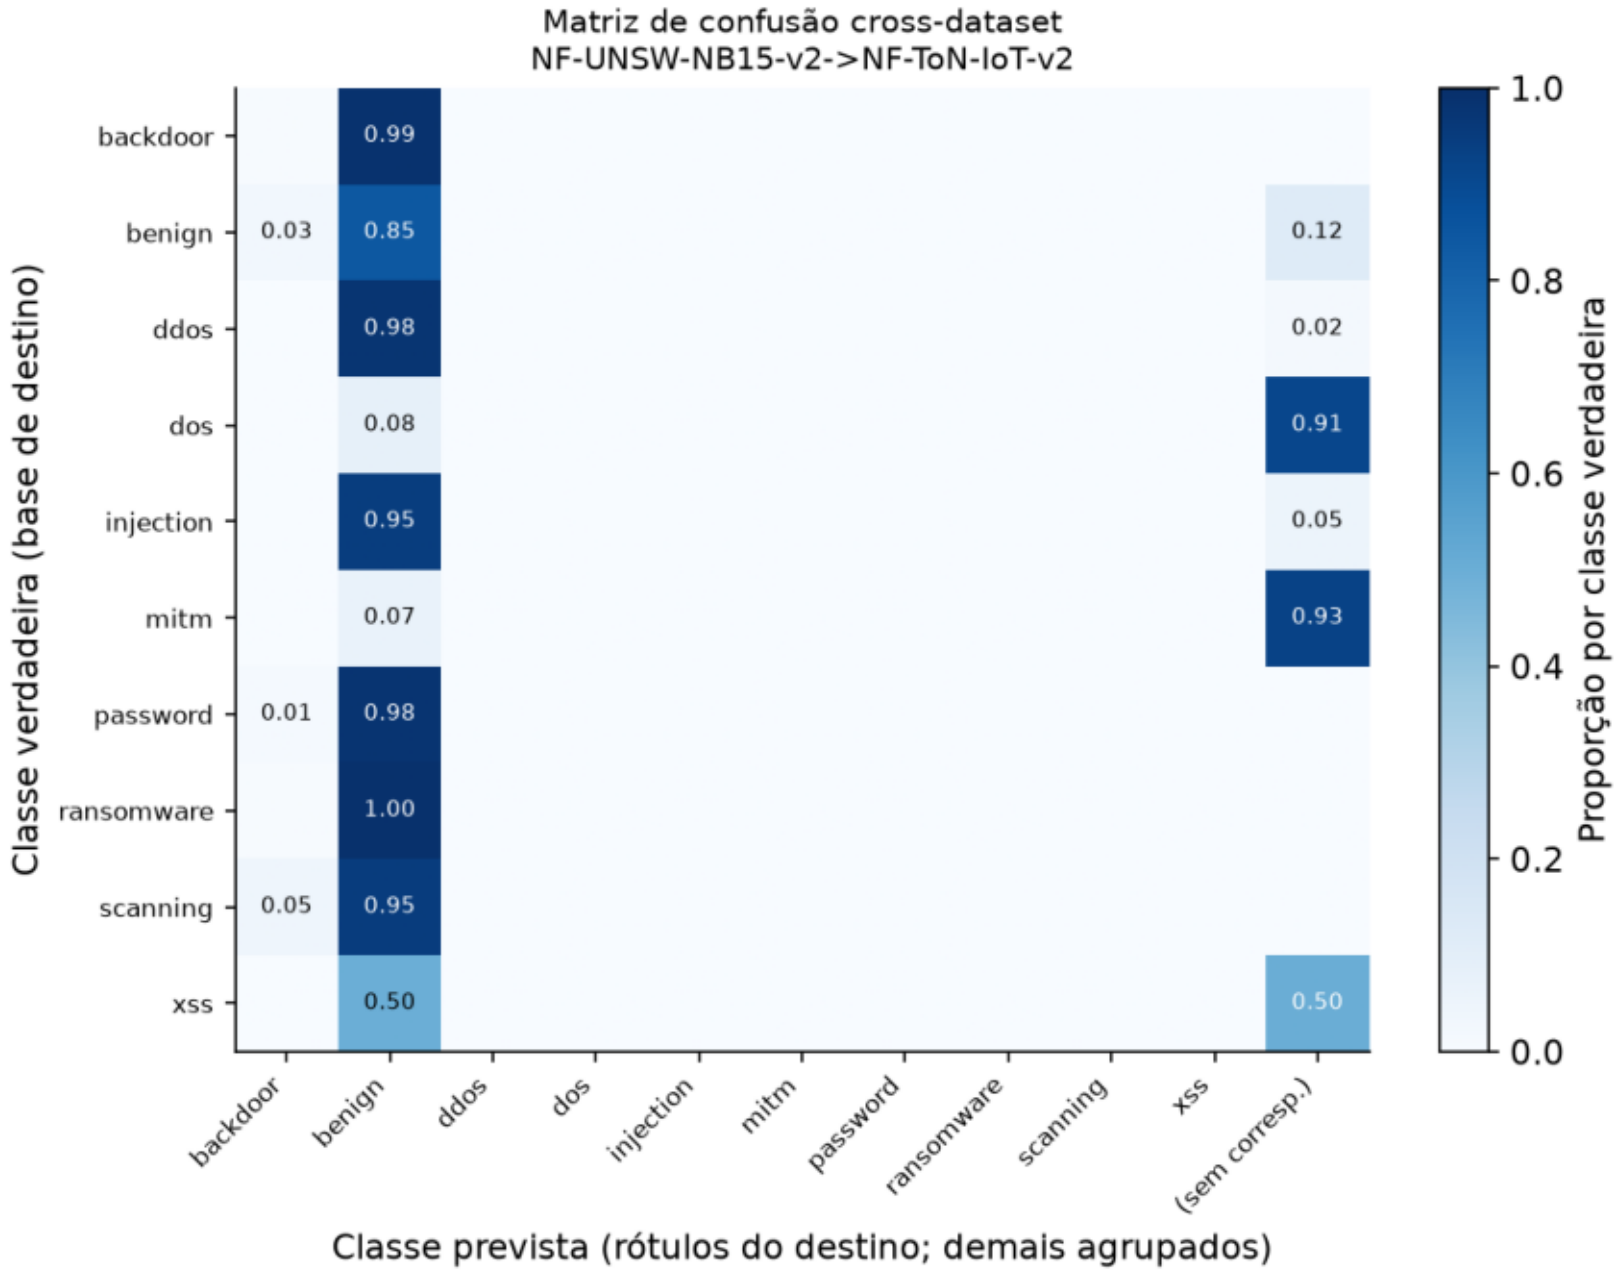

A direção da transferência altera o desempenho
UNSW-NB15 → ToN-IoT
ToN-IoT → UNSW-NB15
F1-macro
0.10
0.08
0.06
0.04
0.02
0.00
0.0545
0.0800
S1 · k=3



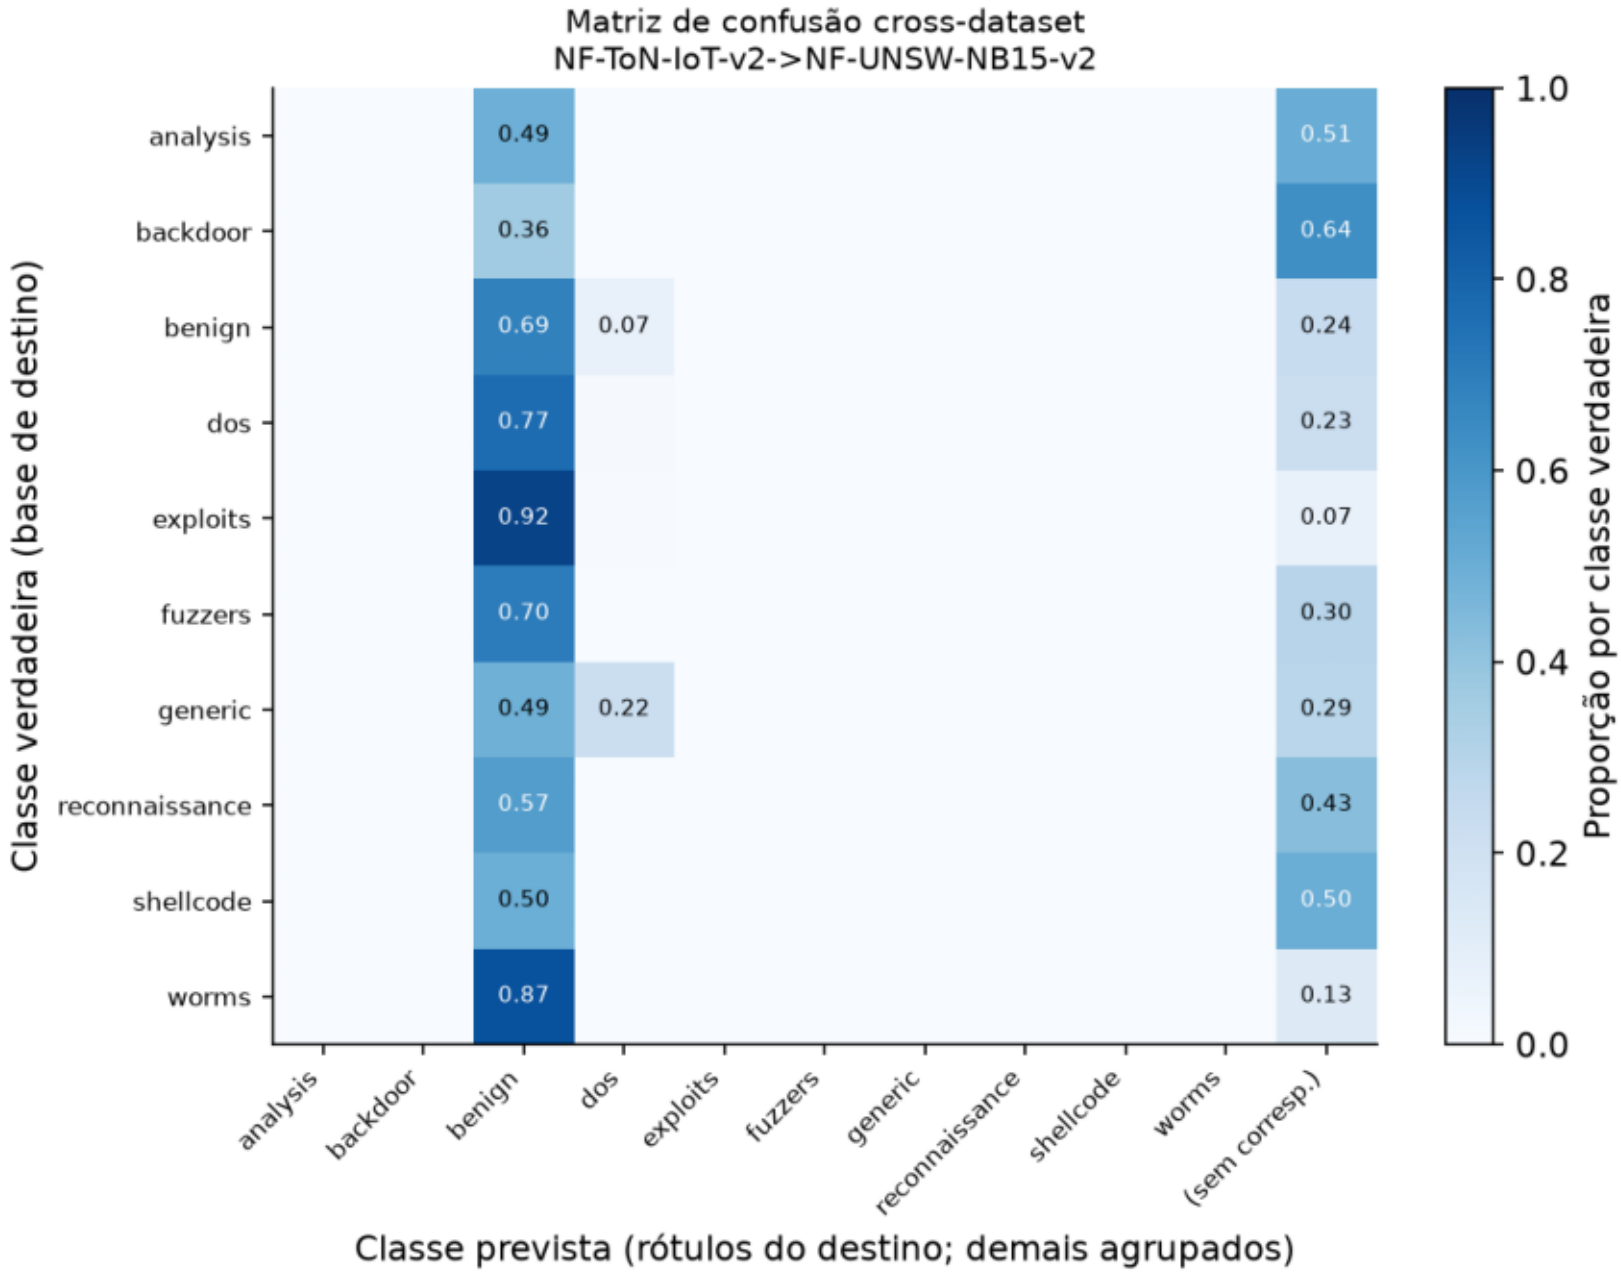
FINAL DA FASE 1 | geração 15/15 | Fase 2: 2/2 avaliações (inclui baseline)

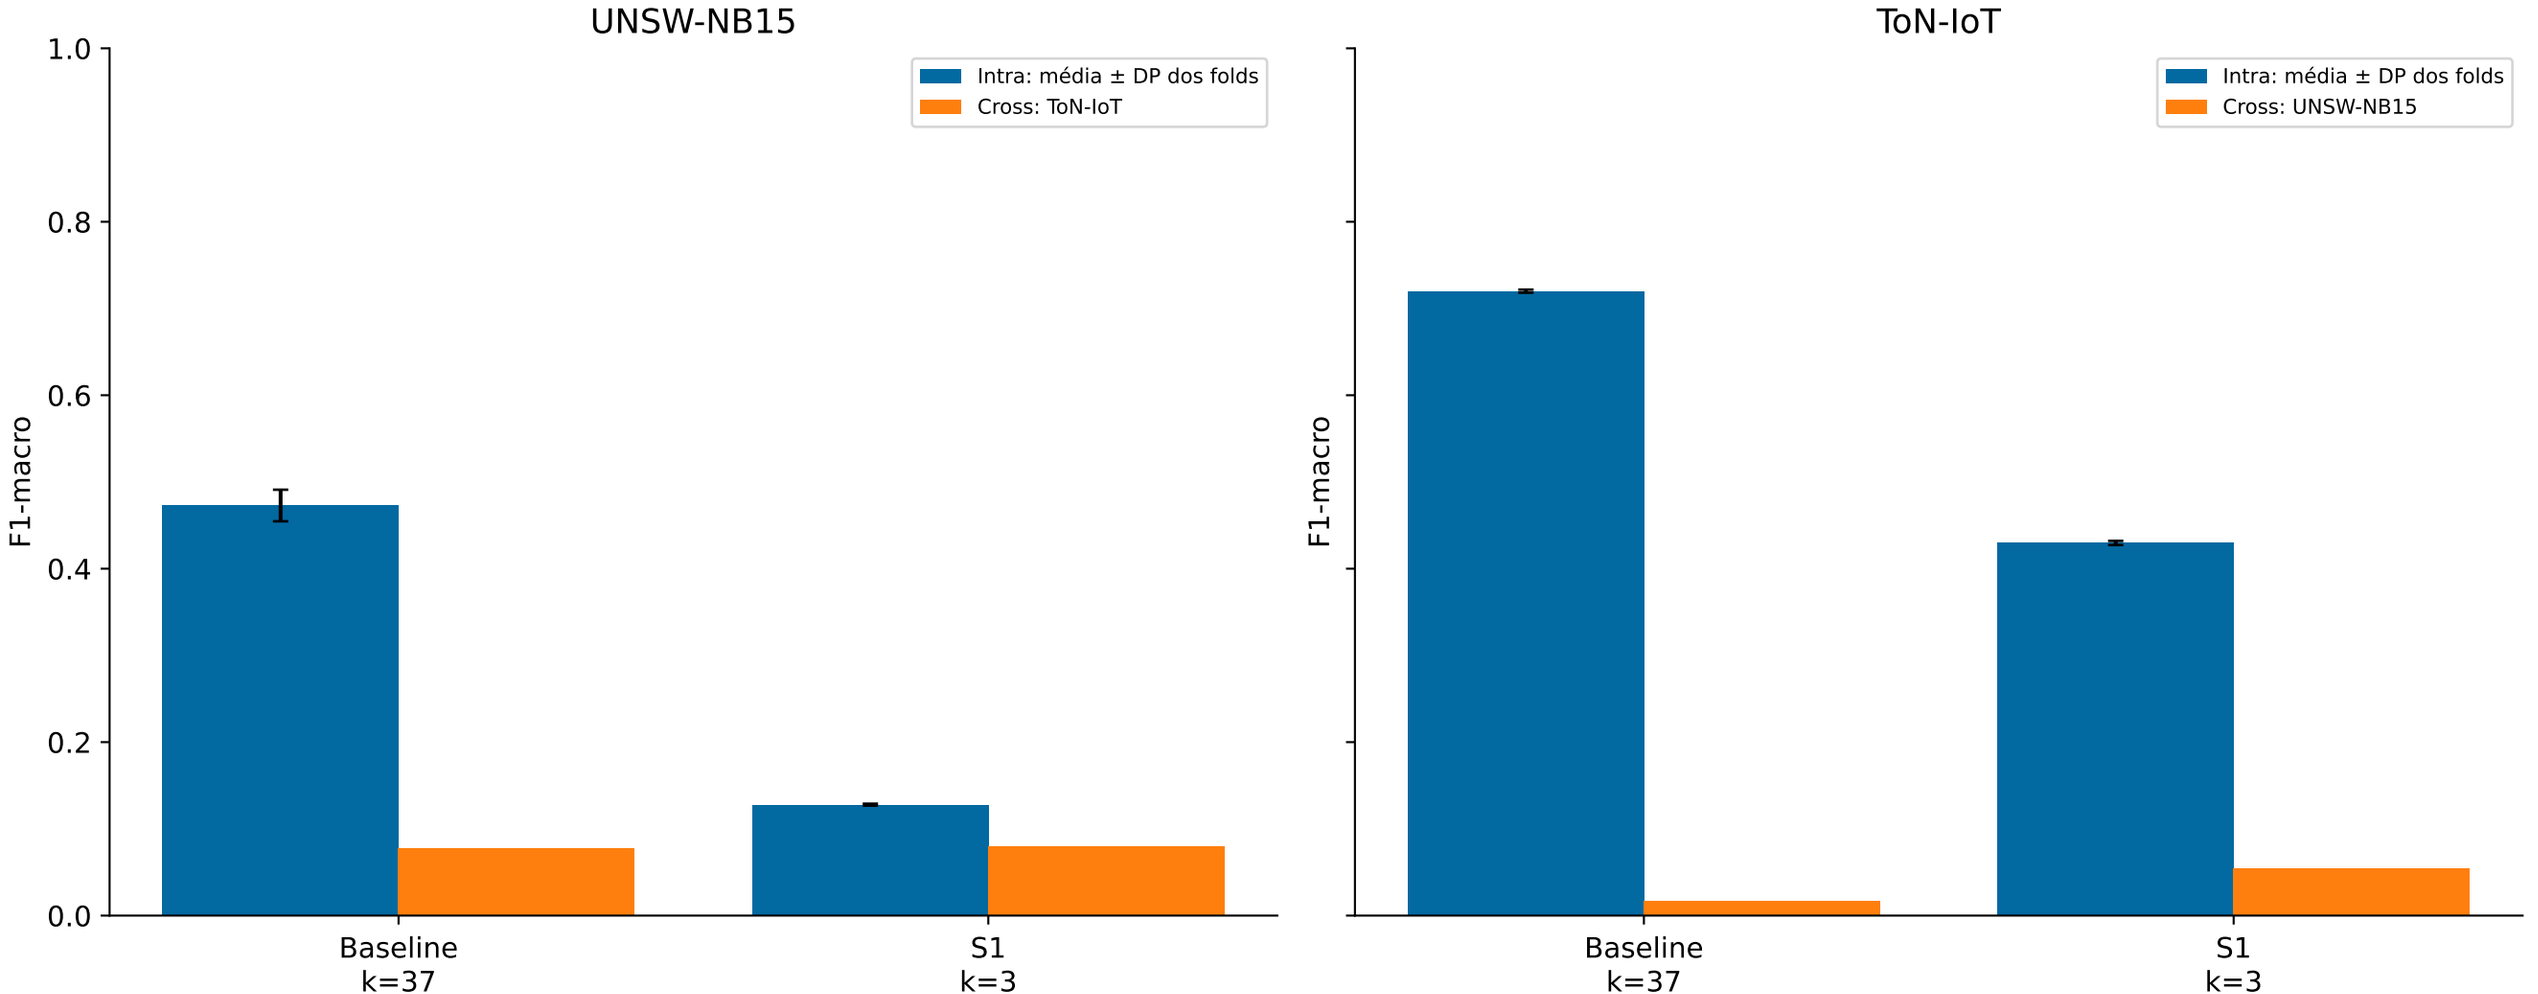

Atributos selecionados em cada solução (azul = selecionado)
S1 · k=3
SERVER_TCP_FLAGS
TCP_WIN_MAX_IN
DNS_QUERY_ID
FINAL DA FASE 1 | geração 15/15 | Fase 2: 2/2 avaliações (inclui baseline)

Solução S1 — 3 atributos



Solução S1 — 3 atributos





FINAL DA FASE 1 | geração 15/15 | Fase 2: 2/2 avaliações (inclui baseline)